PREDICCIÓN DE LA DEMANDA DIARIA DE URGENCIAS HOSPITALARIAS MEDIANTE MODELOS DE APRENDIZAJE AUTOMÁTICO

Alumno: Paula Fernández Sánchez

Tutor: Silvia Jiménez Fernández

Cotutor: Alberto Palomo Alonso

Curso académico 2026-2027

Titulación: Grado en Ingeniería en Tecnologías de Telecomunicación

ÍNDICE.

1. Introducción 2
2. Objetivos y campo de aplicación 3
   Fase 1: Construcción de una base de datos entrenable. 3
   Fase 2: Desarrollo de modelos de predicción de la demanda diaria de urgencias. 3
3. Descripción del trabajo 4
   Fase 1: Construcción de una base de datos entrenable 4
   Fase 2: Desarrollo de modelos de predicción de la demanda diaria de urgencias 4
4. Metodología y plan de trabajo 5
5. Medios 6
6. Bibliografía 6

1. Introducción

La sobreocupación de los servicios de urgencias hospitalarias constituye uno de los problemas operativos más persistentes de los sistemas sanitarios actuales, afectando tanto a la calidad de la asistencia como a la seguridad del paciente y al bienestar del personal sanitario [1]. Esta situación se ve agravada por el carácter irregular de la demanda diaria, que varía en función de patrones estacionales, efectos de calendario (festivos, fines de semana, vacaciones escolares) y otros factores externos. Esta variabilidad dificulta enormemente la planificación anticipada de los recursos humanos y materiales, ya que una infraestimación de la demanda puede derivar en saturación del servicio y tiempos de espera excesivos, mientras que una sobreestimación conlleva un uso ineficiente de los recursos disponibles.

Es en este contexto de incertidumbre donde se enmarca el presente proyecto, cuyo objetivo es el desarrollo de un sistema de predicción de las llegadas diarias a un servicio de urgencias hospitalario, con hasta una semana de antelación, que sirva como herramienta de apoyo a la toma de decisiones en la gestión operativa del servicio.

La predicción de la demanda en urgencias ha sido abordada históricamente mediante métodos estadísticos clásicos de series temporales, tales como los modelos autorregresivos integrados de medias móviles (ARIMA) o el suavizado exponencial. Estos enfoques, resultan robustos y de fácil interpretación, pero presentan limitaciones a la hora de capturar relaciones no lineales entre múltiples variables predictoras [2]. En los últimos años, el auge del aprendizaje automático ha conllevado a la incorporación de algoritmos capaces de integrar de forma conjunta variables de calendario y características derivadas de la propia serie de llegadas, mejorando de forma notable la precisión de las predicciones frente a los métodos puramente estadísticos [3].

En esta línea, estudios recientes han comparado distintas familias de modelos de aprendizaje automático (regresión lineal, árboles de regresión, bosques aleatorios, máquinas de vectores de soporte y redes neuronales) para predecir el volumen diario de visitas a urgencias en horizontes de hasta siete días, empleando datos reales de hospitales españoles [1]. Estos trabajos destacan, además, la relevancia de variables meteorológicas y de calendario en la precisión de las predicciones, así como la importancia creciente de la explicabilidad de los modelos, con el fin de que el personal sanitario pueda comprender y confiar en las predicciones generadas por el sistema [1].

Siguiendo esta línea de trabajo, el presente TFG propone el desarrollo de un sistema de predicción de la demanda diaria de un servicio de urgencias real, utilizando datos históricos de un hospital correspondientes al periodo comprendido entre los años 2022 y 2026. A partir de dicha serie histórica se explorarán distintas aproximaciones de modelado, tanto clásicas como basadas en aprendizaje automático, con el fin de anticipar la afluencia de pacientes con hasta una semana de antelación y proporcionar así una herramienta que facilite la planificación de personal, camas y recursos del servicio.

2. Objetivos y campo de aplicación

El objetivo general del TFG consiste en el desarrollo de un sistema de predicción de las llegadas diarias a urgencias de un hospital, empleando distintos modelos de aprendizaje automático, con el fin de garantizar su éxito, el presente objetivo global se organiza en un conjunto de bloques diferenciados específicos, los cuales se describen a continuación:

Fase 1: Construcción de una base de datos entrenable.

El principal objetivo de esta fase es la obtención de una base de datos entrenable a partir del dato crudo hospitalario. Dicho procedimiento implicará la depuración y estructuración de los datos de entrenamiento, la aplicación de métodos de normalización y la búsqueda e incorporación de variables exógenas que permitan mejorar la capacidad predictiva del sistema.

Fase 2: Desarrollo de modelos de predicción de la demanda diaria de urgencias.

En este bloque se entrenarán y compararán varias familias de predictores con un horizonte de predicción de entre 1 y 7 días, introduciendo además la incertidumbre asociada a cada predicción. También se intentará hacer una predicción desagregada por áreas asistenciales (Pediatría, Ginecología-Obstetricia y resto de áreas), y se desarrollará una interfaz que permita la prueba de los modelos y la visualización de los resultados.

El campo de aplicación de este proyecto es la gestión sanitaria y la planificación de recursos en servicios de urgencias, ámbito en el que una predicción fiable de la demanda puede contribuir a optimizar la asignación de personal, camas y otros recursos hospitalarios.

3. Descripción del trabajo

Como se ha mencionado anteriormente, este desarrollo se divide en dos fases, descritas de forma más exhaustiva y técnica a continuación. El trabajo cubre el ciclo completo dato-modelo-despliegue.

Fase 1: Construcción de una base de datos entrenable

En esta fase, el punto de partida consistirá en la ingesta y curación del dato crudo hospitalario, compuesto por episodios de urgencias y su correspondiente codificación clínica (CIE), procediendo a su depuración y estructuración para su uso posterior en el entrenamiento de modelos. Este proceso incluirá la identificación y tratamiento de registros duplicados, incompletos o inconsistentes, así como la homogeneización de los distintos campos disponibles en un formato unificado.

A continuación, se realizará una agregación temporal de dichos episodios hasta obtener una serie diaria continua correspondiente al periodo 2022-2026, garantizando que no existan discontinuidades en el calendario que puedan distorsionar el entrenamiento de los modelos. Sobre esta serie se incorporarán variables exógenas y se estudiará si permite aportar información relevante para la predicción, tales como indicadores de calendario o fuentes de datos públicas externas. La incorporación de estas variables requerirá, además, un proceso de búsqueda, selección y validación de fuentes fiables, así como su correcta alineación temporal con la serie de llegadas del hospital.

Fase 2: Desarrollo de modelos de predicción de la demanda diaria de urgencias

En esta fase se abordará el modelado propiamente dicho de la demanda diaria de urgencias. El punto de partida consistirá en la utilización de modelos como ARIMA (y sus variantes: SARIMA, SARIMAX), así como otros enfoques de mayor complejidad (árboles de decisión, XGBoost o Transformers), evaluando en cada caso si la mejora de complejidad se traduce en una mejora real de la precisión, así como el estudio de métricas de comparación.

El entrenamiento se realizará bajo un esquema de validación temporal, dividiendo los datos en particiones cronológicas de entrenamiento, validación y test, de forma que ningún modelo se evalúe nunca sobre información anterior a la empleada en su ajuste. Para cada familia de modelos se explorarán distintas configuraciones, tales como el tamaño de la

ventana temporal considerada o el conjunto de variables de entrada empleadas, seleccionando en cada caso la configuración que ofrezca el mejor equilibrio entre precisión y estabilidad de las predicciones a lo largo del horizonte de trabajo definido para el proyecto.

4. Metodología y plan de trabajo

La metodología seguida será de carácter experimental, garantizando una comparación justa entre las distintas familias de predictores, todas ellas evaluadas sobre las mismas particiones temporales (entrenamiento, validación y test). Las familias de modelos consideradas para su implementación son las siguientes:

- Baselines de referencia: modelos de persistencia y naïve estacional semanal, empleados como línea base mínima de comparación.
- Modelos estadísticos clásicos: ARIMA y SARIMAX, incorporando estacionalidad semanal y regresores exógenos de calendario.
- Ensembles de árboles: modelos basados en el conjunto de múltiples árboles de decisión.
- Redes neuronales: tanto arquitecturas tradicionales como arquitecturas profundas.

En cuanto a la planificación temporal se propone un desarrollo que durará 13 semanas. A continuación, en la ilustración 1 podemos consultar el diagrama de Gantt.

DESCRIPCION TAREA	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	S11	S12	S13
Fase 1: Construcción de una base de datos entrenable													
Fase 2: ARIMA/SARIMA/SARIMAX													
Fase 2: Arboles de decisión, XGBoost													
Fase 2: Transformers													
Fase 2: Estudio de métricas de comparación													
Redacción memoria													

Ilustración 1: Diagrama de Gantt

5. Medios

El desarrollo del presente proyecto se llevará a cabo con los siguientes medios:

- Hardware: PC de sobremesa. Se prevé entrenamiento en CPU, dado que los modelos son ligeros y no requieren GPU.
- Software: Python 3.12.
- Datos: episodios de urgencias de un hospital y fuentes públicas.

6. Bibliografía

- [1] Peláez-Rodríguez, C., Torres-López, R., Pérez-Aracil, J., López-Laguna, N., Sánchez-Rodríguez, S., Salcedo-Sanz, S., "An explainable machine learning approach for hospital emergency department visits forecasting using continuous training and multi-model regression," *Computer Methods and Programs in Biomedicine*, 245, 2024.
- [2] Vollmer, M. A., Glampson, B., Mellan, T. et al., "A unified machine learning approach to time series forecasting applied to demand at emergency departments," *BMC Emergency Medicine*, 21(1), 2021.
- [3] Tuominen, J., Lomio, F., Oksala, N. et al., "Forecasting daily emergency department arrivals using high-dimensional multivariate data: a feature selection approach," *BMC Medical Informatics and Decision Making*, 2022.